

LSH Near Duplicate Document Detection

Metodi informatici per la Statistica e il Data Science

Nicola Castelletti, Pietro Stangherlin

Indice

- Background
- Obiettivi
- Metodi utilizzati
- Esperimenti
- Conclusioni

Background

- Problema: in grandi raccolte di documenti (in particolare testuali) è possibile che vi siano dei documenti duplicati o quasi uguali; è inoltre possibile che tali documenti abbiano identificativi diversi o comunque non direttamente riconducibili tra loro.
- Esempi
 - medesimi documenti scannerizzati più volte da entità diverse
 - un'organizzazione che mantiene versioni diverse, ovvero con lievi modifiche, di uno stesso documento

Obiettivi

Implementare un metodo basato su MinHash e LSH per identificare i documenti duplicati e quasi-duplicati.
Valutarne l'efficacia ed effettuare considerazioni sull'efficienza.

Metodi utilizzati

- Shingling
- MinHash
- LSH

MinHash

Dimensione delle shingles: $w = 9$ (Leskovec, Rajaraman e Ullman 2014)
(parametro fissato, seguendo le indicazioni sul libro di testo)

Salvataggio signatures

- scrittura su disco (database sql) (scelta impiegata)
- memoria centrale (es. btree) (non considerata, possibile per piccole collezioni)

Stima della memoria occupata dalle signatures y :

$$y = d \times p \times n$$

Con

- d : bit occupati da ciascun elemento della signature
- p : n° di permutazioni
- s : n° di documenti nella collezione

Esempio: con 100 permutazioni, interi a 32 bit e 10^6 documenti: $y = 400$ megabyte.

SignatureHash

Per approssimare ciascuna permutazione in ogni elemento delle signature si impiegano delle funzioni hash. Come descritto in Broder et al. 1998, alla base di molti schemi di hashing, tra cui quello considerato, vi è che ogni funzione hash $h : U \rightarrow [m]$ sia casuale. Tale assunzione non può ovviamente essere soddisfatta e si ricorre dunque a delle approssimazioni. Si dice che una famiglia di funzioni hash $H = \{h | h : U \rightarrow [m]\}$ è (debolmente) universale se $\forall x_1 \neq x_2 \in U$ e estraendo h uniformemente da H si ha $\Pr\{h(x_1) = h(x_2)\} \leq \frac{1}{m}$. Una semplice implementazione di una famiglia di funzioni hash universale è (Indyk e Motwani 1998)

$$h(x) = [(a * x + b) \bmod p] \bmod m, \text{ con}$$

- a, b interi estratti casualmente
- p numero primo (maggiore di m)

LSH

Implementazioni

- in memoria di massa (non considerata)
- in memoria centrale: ogni bucket è implementato come una linked list
 - Lista: ogni banda ha $P * N$ bucket con N numero di documenti e p fattore di scala > 1 , il tempo di accesso ad ogni bucket è $O(1)$, al costo di memoria occupata dai bucket vuoti.
 - Btree (libreria Btrees): non sono presenti bucket vuoti, il tempo di accesso a ogni bucket è $O(\log_2[N])$
- in memoria centrale in un cluster (ad esempio via MapReduce)

In tutti i casi è conveniente salvare gli indirizzi dei bucket con almeno due elementi (evita inutili controlli successivi).

Per ogni banda, considerata una signature $v = (v_1, v_2, \dots, v_d)^\top$ si impiega la funzione hash $h(x) = \left(\sum_{j=1}^d v_j a_j \right) \bmod N * P$ con $a = (a_1, a_2, \dots, a_d)^\top$ vettore di numeri (pseudo)casuali (Indyk e Motwani 1998).

Scalabilità

La procedura di minhash è scalabile in quanto la creazione di ciascuna signature è indipendente dalle altre ed è effettuata in batch di documenti. LSH invece richiede soluzioni alternative: qui si è scelta una procedura basata su MapReduce che è stata testata su dei casi isolati ma non impiegata per tutta la procedura per l'analisi dell'effetto dei parametri in quanto avrebbe richiesto la spesa di risorse economiche su servizi online (si è considerato Azure). Per l'implementazione in MapReduce:

- La chiave considerata è la coppia id della banda e id del bucket, il valore l'id del documento.
- Si è fatto ricorso a una doppia procedura in cui nella prima fase si sono ottenuti gli elementi con gli insiemi di documenti nella stessa banda e bucket; nella seconda fase per ogni coppia di documenti si è effettuato il conteggio di bucket in comune.

Misure di similarità

- numero di bucket condivisi tra due documenti: ottenuta da LSH
- similarità delle signature: l'accesso ai record del database per ogni confronto è molto lento, si è quindi ricorsi ad un caching delle signature: per tutti i documenti presenti in almeno una coppia si popola un dizionario di signature. Popolare il dizionario ha un costo di $O(N)$ (lettura dei record del database), ma ogni confronto richiederà $O(1)$ per leggere le signature.

Esperimenti

- Collezione impiegata per la valutazione dell'effetto dei parametri: Robust (dimensione iniziale 1.45 GB).
- Prima esecuzione della procedura sulla collezione originale (senza semi-duplicati artificiali) per tarare i parametri e valutare il massimo grado di similarità presente tra documenti della collezione originale. Rimozione dei documenti con similarità alta per migliorare le valutazioni sui dati semi-artificiali.
- Esecuzioni successive con diversi livelli di modifica dei documenti semi-duplicati artificiali
- Problemi:
 - lo spazio dei parametri è vasto
 - negli articoli di riferimento non sono considerati gli effetti delle diverse combinazioni di parametri
 - ottenere i risultati di una singola configurazione è costoso

Creazione della collezione sperimentale

- 1 Si assume di avere una collezione iniziale senza duplicati e quasi – duplicati. Ogni documento presenta un codice identificativo (id).
- 2 Si seleziona (ad esempio tramite un generatore di numeri casuali) un sottoinsieme di documenti da cui generare i duplicati e i quasi duplicati.
- 3 Quasi duplicati: sostituzione di alcuni caratteri con altri (casuali), per simulare un risultato di un programma di riconoscimento ottico di testo. Il parametro relativo alla frequenza di sostituzione è la percentuale sul numero totale di caratteri nel testo
- 4 A ogni quasi-duplicato si assegna un id univoco (id2) e l'id del documento da cui è stato generato (id3). Viene creata una nuova collezione con i quasi-duplicati e i documenti originali (per questi ultimi il campo l'id3 è posto uguale a None)

Id	text
1	hello world
2	Bob, Alice and Ulm
3	nosce te ipsum




id2	id3	text
1	None	hello world
2	None	Bob, Alice and Ulm
3	None	nosce te ipsum
4	3	n@sCe t3 ipsuN

Parametri degli esperimenti


- Rumore nei semi-duplicati: nessuno (0%), “piccolo” (2%), “medio” (5%)
- Percentuale di duplicati relativo alla dimensione della collezione: 1%, 5%, 10%, 25%.
- Lunghezza signature: 100, 200
- Numero di bande: 10, 20
- Numero di bucket relativo alla dimensione della collezione: 2, 5, 10

Combinazioni totali per collezione: 192.

Risultati Low




(a) low 1




(b) low 2

Risultati Mid




(a) mid 1




(b) mid 2

Risultati High




(a) high 1



(b) high 2

Risultati Signature Similarity vs Shared Bucket



Memory Profiling


Benché Python non permetta una precisa gestione della memoria si è eseguito un memory profiler (libreria memory-profiler) per le implementazioni di LSH (non map-reduce) tramite liste e btree fissando i parametri.

nba	nbu	sigl	ndoc	List (Mb)	Btree (Mb)
10	25	200	645613	2500	1400
20	10	200	645613	3300	2600
20	25	100	645613	4600	2550
20	25	200	645613	4750	2600

Collezione Arxiv Abstracts

Si è provato ad applicare il metodo sulla collezione di abstract di arxiv (<https://www.kaggle.com/datasets/Cornell-University/arxiv>) con più di 1.7 milioni di documenti (circa 2.8 GB dopo preprocessing). I parametri fissati a:

- lunghezza della signature: 100
- numero di bande: 10
- numero di bucket relativo alla dimensione della collezione: 10



Conclusioni

Difficoltà emerse:

- La creazione della collezione per la valutazione dell'effetto dei parametri ha richiesto delle scelte arbitrarie.
- Lo spazio dei parametri è vasto.
- Python non permette una accurata gestione della memoria (a differenza ad esempio di C), questo può essere sia un pro che un contro, nel nostro caso ciò ha reso difficilmente interpretabile l'impiego di memoria tramite profiling.

Cosa si è imparato:

- Documentare le funzioni può richiedere più tempo della scrittura del codice stesso
- Scalare il metodo senza sacrificare eccessiva velocità richiede investimenti in termini di memoria centrale (eventualmente noleggiando dei server).

Sviluppi futuri

- Valutare le differenze con diverse tipologie di collezioni.
- Considerare implementazioni in C/C++.

Bibliografia I

-  Broder, Andrei et al. (gen. 1998). “Min-wise independent permutations (extended abstract)”. In: DOI: 10.1145/276698.276781.
-  Indyk, Piotr e Rameev Motwani (1998). “Approximate nearest neighbors: towards removing the curse of dimensionality”. In: STOC '98, pp. 604–613. DOI: 10.1145/276698.276876. URL: <https://doi.org/10.1145/276698.276876>.
-  Leskovec, Jure, Anand Rajaraman e Jeffrey D. Ullman (2014). *Mining of Massive Datasets*. Second. Cambridge University Press. URL: <http://mmds.org>.