

LSH Near Duplicate Document Detection

Nicola Castelletti, Pietro Stangherlin

Indice

- Background
- Obiettivi
- Metodi utilizzati
- Esperimenti
- Conclusioni

Background

- Problema: in grandi raccolte di documenti (in particolare testuali) è possibile che vi siano dei documenti duplicati o quasi uguali; è inoltre possibile che tali documenti abbiano identificativi diversi o comunque non direttamente riconducibili tra loro.
- Esempi
 - medesimi documenti scannerizzati più volte da entità diverse
 - un'organizzazione che mantiene versioni diverse, ovvero con lievi modifiche, di uno stesso documento

Obiettivi

Implementare un metodo basato su MinHash e LSH per identificare i documenti duplicati e quasi-duplicati.

Valutarne l'efficacia e ed effettuare considerazioni sull'efficienza.

Metodi utilizzati

- Creazione della collezione sperimentale
- Shingling
- MinHash
- LSH

Creazione della collezione sperimentale

- 1 Si assume di avere una collezione iniziale senza duplicati e quasi – duplicati. Ogni documento presenta un codice identificativo (id).
- 2 Si seleziona (ad esempio tramite un generatore di numeri casuali) un sottoinsieme di documenti da cui generare i duplicati e i quasi duplicati.
- 3 Quasi duplicati: sostituzione di alcuni caratteri con altri (casuali), per simulare un risultato di un programma di riconoscimento ottico di testo. Il parametro relativo alla frequenza di sostituzione è la percentuale sul numero totale di caratteri nel testo
- 4 A ogni quasi-duplicato si assegna un id univoco (id2) e l'id del documento da cui è stato generato (id3). Viene creata una nuova collezione con i quasi-duplicati e i documenti originali (per questi ultimi il campo l'id3 è posto uguale a None)

Id	text
1	hello world
2	Bob, Alice and Ulm
3	nosce te ipsum



id2	id3	text
1	None	hello world
2	None	Bob, Alice and Ulm
3	None	nosce te ipsum
4	3	n@sCe t3 ipsuN

MinHash

Dimensione delle shingles: $w = 9$ **leskovec2014mining** (parametro fissato, seguendo le indicazioni sul libro di testo)

Salvataggio signatures

- scrittura su disco (database sql) (scelta impiegata)
- memoria centrale (es. btree) (non considerata, possibile per piccole collezioni)

Stima della memoria occupata dalle signatures y :

$$y = d \times p \times n$$

Con

- d : bit occupati da ciascun elemento della signature
- p = n° di permutazioni
- s = n° di documenti nella collezione

Esempio: con 100 permutazioni, interi a 32 bit e 10^6 documenti: $ms = 400$ megabyte.

SignatureHash

Come descritto in **BroderMin-wise**, alla base di molti schemi di hashing, tra cui quello considerato, vi è che ogni funzione hash $h : U \rightarrow [m]$ (adottata per ogni elemento della signature) sia casuale. Tale assunzione non può ovviamente essere soddisfatta e si ricorre dunque a delle approssimazioni. Si dice che una famiglia di funzioni hash $H = \{h | h : U \rightarrow [m]\}$ è (debolmente) universale se $\forall x_1 \neq x_2 \in U$ e estraendo h uniformemente da H si ha $\Pr \{h(x_1) = h(x_2)\} \leq \frac{1}{m}$. Una semplice implementazione di una famiglia di funzioni hash universale è $h(x) = [(a * x + b) \bmod p] \bmod m$, con

- a, b interi estratti casualmente
- p numero primo (maggiore di m)

LSH

Implementazioni

- in memoria di massa (non considerata)
- in memoria centrale: ogni bucket è implementato come una linked list
 - Lista: ogni banda ha $P * N$ bucket con N numero di documenti e p fattore di scala > 1 , il tempo di accesso ad ogni bucket è $O(1)$, al costo di memoria occupata dai bucket vuoti.
 - Btree: non sono presenti bucket vuoti, il tempo di accesso a ogni bucket è $O(\log_2[N * P])$

In tutti i casi è conveniente salvare gli indirizzi dei bucket con almeno due elementi (evita inutili controlli successivi).

Per ogni banda, considerata una signature $v = (v_1, v_2, \dots, v_d)^\top$ si impiega la funzione hash $h(x) = \left(\sum_{j=1}^d v_j a_j\right)$ modulo $N * P$ con $a = (a_1, a_2, \dots, a_d)^\top$ vettore di numeri casuali.

Misure di similarità

- numero di bucket condivisi tra due documenti: ottenuta da LSH
- similarità delle signature: l'accesso ai record del database per ogni confronto è molto lento, si è quindi ricorsi ad un caching delle signatures: per tutti i documenti presenti in almeno una coppia si popola un dizionario di signature. Popolare il dizionario ha un costo di $O(N)$ (lettura dei record del database), ma ogni confronto richiederà $O(1)$ per leggere le signature.

Esperimenti

- Prima esecuzione della procedura sulla collezione originale (senza semi-duplicati artificiali) per tarare i parametri e valutare il massimo grado di similarità presente tra documenti della collezione originale. Rimozione dei documenti con similarità alta per migliorare le valutazioni sui dati semi-artificiali.
- Esecuzioni successive con diversi livelli di modifica dei documenti semi-duplicati artificiali
- Problemi:
 - lo spazio dei parametri è grande
 - gli articoli non forniscono molte indicazioni
 - ottenere i risultati di una singola configurazione è costoso

Parametri degli esperimenti

- Rumore nei semi-duplicati: nessuno (0%), “piccolo” (2%), “medio” (5%)
- Percentuale di duplicati relativo alla dimensione della collezione: 1%, 5%, 10%, 25%.
- Lunghezza signature: 100, 200
- Numero di bande: 10, 20
- Numero di bucket relativo alla dimensione della collezione: 2, 5, 10

Combinazioni totali per collezione: 192.

Conclusioni