Corso di laurea magistrale in Scienze Statistiche
Metodi informatici per statistica e data science
2023/2024

Università degli Studi di Padova

Mini-progetto

LSH near duplicate document detection

Pietro Stangherlin 2129207
Nicola Castelletti 2109302

2023/2024

Indice della presentazione

- Obiettivi
- Metodi utilizzati
- Esperimenti
- Conclusioni

Background

Problema: in grandi raccolte di documenti (in particolare testuali) è possibile che vi siano dei documenti duplicati, quasi uguali, oppure che un documento sia già contenuto in un altro; è inoltre possibile che tali documenti abbiano identificativi diversi o comunque non direttamente riconducibili tra loro.

Degli esempi possono essere:
- medesimi documenti scannerizzati più volte da entità diverse.
- un'organizzazione che mantiene versioni diverse, ovvero con lievi modifiche, di uno stesso documento.

Obbiettivi

Sviluppare un metodo basato su MinHash e LSH per identificare i documenti quasi-duplicati.

Valutare l’efficacia e analizzare l’efficienza
-> Specifica misure di efficacia

Metodi utilizzati

- Creazione della collezione sperimentale
- Shingling
- MinHash
- LSH

Creazione collezione sperimentale (1)

1) Si assume di avere una collezione iniziale senza duplicati e quasi – duplicati. Ogni documento presenta un codice identificativo (id).
2) Si seleziona (ad esempio tramite un generatore di numeri casuali) un sottoinsieme di documenti da cui generare i quasi duplicati.
3) Scelta del tipo di modifica dei documenti per la creazione dei semi duplicati: sostituzione di alcuni caratteri con altri (random), per simulare un risultato di un programma di riconoscimento ottico di testo. Parametro relativo alla frequenza di sostituzione (bassa o elevata)

Creazione collezione sperimentale (2)

4) A ogni quasi–duplicato si assegna un id univoco (id1) e l'id del documento da cui è stato generato (id2). Viene creata una nuova collezione con i quasi-duplicati e i documenti originali (per questi ultimi il campo l'id2 è posto uguale a None)

Id	text
1	hello world
2	Bob, Alice and Ulm
3	nosce te ipsum

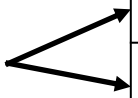

id1	id2	text
1	None	hello world
2	None	Bob, Alice and Ulm
3	None	nosce te ipsum
4	3	n@sCe t3 ipsuN

Creazione collezione sperimentale (3)

4)Durante la creazione della nuova collezione si crea una struttura dati (ad esempio dizionario) o file in cui per ogni id di un documento originale sono associati gli id dei documenti artificiali (o viceversa), in questo modo la procedura di valutazione è più efficiente.

Shingling (1)

- Dimensione delle shingles: w = 9 [5]
- Trattamento caratteri speciali (spazio, newline etc)
- Salvataggio delle shingles, proposte di [1]:
  - Salvare anche la frequenza delle shingles nel documento (o usare una shingle più volte) -> possibilmente confrontare
  - Salvare solo le shingles uniche (maggiore efficienza)
- Hash per le shingles (quasi necessaria per ridurre memoria occupata dalla signature): compromesso tra memoria (definizione del numero di bit dell'hash) impiegata e numero di collisioni per shingles diverse. [1] consiglia di impiegare la Rabin Fingerprint [7]. Considerare anche il Rolling Hashing [8] (concetto simile a calcolo di una media mobile)

Shingling (2)

- Struttura dati per salvare le shingles (i loro hash): l'insieme delle shingles è temporaneo, serve solo per calcolare la signature, poi è eliminato
  - Lista:
    - Contro: occupa più memoria del necessario per shingle ripetute
    - Contro: le shingle ripetute causano delle inutili operazioni in più nel calcolo delle signatures ()
  - Hash set
    - Pro: shingle ripetute sono considerate una sola volta
    - Contro: affinché non vi siano eccessive collisioni tra le chiavi una parte di memoria dell hash set deve essere vuota, tuttavia, ad eccezione di testi di dimensioni fuori scala ciò non dovrebbe essere un problema

MinHash (1)

- Valutare se le signatures di tutti i documenti possono risiedere in memoria centrale, altrimenti
  - Scrittura su disco
  - Modifica parametri delle shingles e delle permutazioni

  Stima della memoria occupata dalle signatures (ms):

  ms = bit_int * num_perm * n_doc

  Con
  - dim_int = bit occupati da ciascun elemento della signature
  - num_perm = n° di permutazioni
  - n_doc = n° di documenti nella collezione

  Esempio, con 100 permutazioni, interi a 32 bit e 600’000 documenti: ms = 240 megabyte

MinHash (2)

- Scelta della struttura dati per le signatures: ciascun documento deve essere identificabile tramite id (per i confronti tra bande di signatures dopo LSH).
- In una possibile implementazione (memory wise) non vengono mantenute in memoria le signatures: ciascuna signature è impiegata per eseguire LSH e poi è rimossa dalla memoria (in questo caso ci si aspetta una riduzione delle precisione poiché l'unico criterio di similarità è basato sui bucket LSH)
- Nella costruzione del MinHash: valutare se tenere in memoria un dizionario con gli hash già calcolati di alcune shingles

MinHash (3)

Scelta del numero k di permutazioni e relative funzioni hash.

Hashing universale[6].

h : U -> [m] (bins).

Famiglia H:{h: U -> [m]} è detta k-universale se per ogni x != y in U si ha |{h in H: h(x) = h(y)}| <= |H|/(m^k).

Una semplice implementazione da [6] è la famiglia di funzioni: h(x) = [(a*x + b) mod p] mod m

Con a e b interi estratti casualmente e p numero primo.

LSH

- Numero di bande
- Funzioni hash per la bande
- Struttura dati per i bucket: hash-table dove ad ogni chiave è associata una lista con gli id dei documenti
- Diverse implementazioni:
  - in memoria centrale
    - Hash-table
    - Hash-tree o b-tree
  - In memoria di massa

LSH

Per calcolare le similarità tra documenti è necessario conoscere quali documenti sono nel medesimo bucket, se ciò è fatto solo dopo che tutti i documenti sono stati elaborati è necessario visitare ogni bucket, un'alternativa è di individuare i documenti simili ogni volta che un documento è inserito in un bucket.

Quando un documento è inserito in un bucket si esegue un controllo di similarità con tutti gli altri documenti già presenti nel bucket.

Esperimenti

- Prima esecuzione della procedura sulla collezione originale (senza semi-duplicati artificiali) per tarare i parametri e valutare il massimo grado di similarità presente tra documenti della collezione originale
- Esecuzioni successive con diversi livelli di modifica dei documenti semi-duplicati artificiali

Conclusioni

Bibliografia

1. A.Z. Broder, “On the resemblance and containment of documents,” Proc. Compression and Complexity of Sequences, pp. 21–29, Positano Italy, 1997
2. A.Z. Broder, M. Charikar, A.M. Frieze, and M. Mitzenmacher, “Min-wise independent permutations,” ACM Symposium on Theory of Computing, pp. 327–336, 1998.
3. P. Indyk and R. Motwani. “Approximate nearest neighbor: towards re moving the curse of dimensionality,” ACM Symposium on Theory of Com puting, pp. 604–613, 1998.
4. A. Gionis, P. Indyk, and R. Motwani, “Similarity search in high dimensions via hashing,” Proc. Intl. Conf. on Very Large Databases, pp. 518 529, 1999
5. J. Leskovec, A. Rajaraman, and J. Ullman. “Mining of Massive Dataset“ Cambridge University Press, Second edition, (2014)

Bibliografia

6. J.Lawrence Carter, Mark N. Wegman,Universal classes of hash functions, Journal of Computer and System Sciences, Volume 18, Issue 2,1979,Pages 143-154.

7. Michael O. Rabin (1981). "Fingerprinting by Random Polynomials. Center for Research in Computing Technology, Harvard University.

8. Jonathan D. Cohen. 1997. Recursive hashing functions for n-grams. ACM Trans. Inf. Syst. 15, 3 (July 1997), 291–320.